

机器学习重点



Author: 潜伏

写作日期: 2026-06-06

主题: machine_learning 期末复习重复考点整理

优先级	知识点	出现频率	常见考法	复习要求
S 级	决策树 ID3、 信息熵、 信息增益、剪枝	4/4	算熵、算信息增益、 画决策树、简述后剪枝	必须会手算和画树
S 级	聚类: K- means、 合并聚类、 聚类定义、SSE	4/4	给样本点手推 K-means 每轮结果; 解释聚类目标	必须会完整迭代过程
S 级	线性分类器 / 线性判别函数 / 多类拆分	4/4	几何意义、判别面、 距离公式、多分类策略、 最小欧氏距离分类器	必须会写公式和解释几何意义
S 级	神经网络: 感知器、Delta 法则、XOR、 RBF、 神经元模型	4/4	画神经元、写训练法则、 比较感知器法则和 Delta 法则、画两层网络	必须会画图 + 写更新公式
S 级	贝叶斯学习: 朴素贝叶斯、 MAP/ML、 极大似然证明	4/4	写分类公式、手算分类、 解释零概率、 证明平方误差最小化等价于 MLE	必须会公式和证明模板
S 级	遗传算法 GA	4/4	写算法流程/伪代码、 解释编码、适应度、 选择交叉变异	必须会背流程并能套到特征选择
A 级	特征选择: Filter/Wrapper、	3/4	简述搜索方式、 特征子集搜索、特征分类	重点背概念和优缺点

优先级	知识点	出现频率	常见考法	复习要求
	前向/后向搜索、 Relief-F			
A 级	基础概念： 学习、 归纳学习、 概念学习、 过拟合、 无偏学习	3/4	概念题、简答题	必背，分值小但稳定
B 级	SVM：硬间隔、 软间隔、 核函数、 支持向量	习题高频	简答与几何解释	有时间必须补，可能作为新题
B 级	Logistic / 正则化 / 梯度下降 / 线性回归	习题 + 2025	手算最小二乘、 解释学习率、正则化	中高优先级
C 级	RNN、LSTM、 Transformer、 位置编码	习题出现	概念简答	最后复习，防止出拓展题

贝叶斯公式应用

朴素贝叶斯的“朴素”假设是：给定类别后，各属性之间条件独立

核心公式

最大后验概率（MAP）分类器的核心公式为：

$$h_{MAP} = \arg \max_{h_j \in V} P(h_j \mid x_1, x_2, \cdots, x_n)$$

根据贝叶斯公式：

$$P(h_j \mid x_1, \cdots, x_n) = \frac{P(x_1, \cdots, x_n \mid h_j)P(h_j)}{P(x_1, \cdots, x_n)}$$

在进行分类预测时，分母 $P(x_1, \cdots, x_n)$ 对所有类别 h_j 都是相同的常数，因此在求最大值时可以忽略，只需比较分子部分：

$$h_{MAP} = \arg \max_{h_j \in V} P(h_j) P(x_1, \dots, x_n | h_j)$$

朴素贝叶斯分类器

朴素的核心假设是：给定类别后，各个属性（特征）之间相互条件独立。因此联合概率可以拆解为各属性条件概率的乘积：

$$P(x_1, \dots, x_n | h_j) = \prod_{i=1}^n P(x_i | h_j)$$

将该假设代入后，得到最终的朴素贝叶斯分类公式：

$$h_{NB} = \arg \max_{h_j \in V} P(h_j) \prod_{i=1}^n P(x_i | h_j)$$

⚠ **考试避坑提示：**如果题目中某个属性值在某个类别下从未出现过（概率为 0），会导致整项乘积变为 0。请注意题目是否要求使用**拉普拉斯平滑（Laplacian Smoothing）**进行修正。

聚类 k-means

计算方法：

- 选定每个簇初始中心
- 然后根据(欧几里得距离/曼哈顿距离)，离哪个簇近，就归到哪个簇
- 然后根据簇中的点，计算横纵坐标的平均值作为新中心点
- 然后根据新中心点重新确定每个簇的点，反复迭代知道簇中点不变

簇与簇之间的距离：

- 单链接：两个簇之间最近点的距离
- 全链接：两个簇之间最远点的距离
- 平均链接：两个簇之间所有点对距离的平均值

计算方式：

- 初始时每个点单独成簇。
- 计算所有簇之间距离。
- 合并距离最近的两个簇。
- 更新簇间距离。
- 重复直到剩下指定数量的簇。

决策树 熵与信息增益

$$Entropy(S) = -p_+ \log_2 p_+ - p_- \log_2 p_-$$

信息增益公式：

$$Gain(S, A) = Entropy(S) - \sum_{v \in \text{Values}(A)} \frac{|S_v|}{|S|} Entropy(S_v)$$

也就是：信息增益=划分前的熵-按属性划分后的加权熵

决策树预剪枝三种策略：

- 限制决策树的深度
- 限制节点的最小样本数
- 限制最小信息增益

决策树后剪枝两种策略：

- 错误率降低修建：如果把某个子树替换成叶子节点后，在验证集上的错误率没有上升，甚至下降，那么就剪掉这个子树。
- 规则后修剪策略：先把决策树转化成一组 if-then 分类规则，然后对每条规则单独修剪，删除规则中不必要的条件。

C4.5算法：

使用信息增益率，防止把数据切的过于碎(例如每个人的学号是独一无二的，但是把学号用作分类依据是不合理的)

$$GainRatio(S, A) = \frac{Gain(S, A)}{SplitInfo(S, A)}$$

$$SplitInfo(D, A) = - \sum \frac{|D_v|}{|D|} \log_2 \left(\frac{|D_v|}{|D|} \right)$$

遗传算法

描述遗传算法流程：

遗传算法是一种模拟自然选择和遗传机制的随机搜索算法。其基本流程如下：

1. 对问题的候选解进行编码，形成染色体；
2. 随机产生初始种群；
3. 计算种群中每个个体的适应度，并根据适应度进行选择；
4. 对父代个体进行交叉操作，产生子代；
5. 对子代个体以一定概率进行变异；
6. 回到 Step2 并重复上述过程，直到达到最大迭代次数或适应度满足要求；

伪代码写法：

GeneticAlgorithm():

P = 初始化种群

while 未满足终止条件:

 计算 P 中每个个体的适应度

 根据适应度进行选择, 得到父代个体

 对父代个体进行交叉, 产生子代

 对子代进行变异

 形成新一代种群 P

返回适应度最高的个体

选择算法;

- 轮盘赌选择: 取一组个体, 它们活下来的概率与适应度大小成正比。
 - 优缺点:
 - 适应度高的个体被选中概率大
 - 但仍有概率选中较差的个体, 保持多样性
 - 可能导致高适应度个体迅速占据主导 (拥挤问题)
- 锦标赛选择: 随机抽取若干个个体, 让他们比赛, 选择适应度最高的个体
- 排名选择: 按适应度对假设进行排序, 而非与适应度值成比例
 - 优点:
 - 避免高适应度个体过度主导, 保持多样性

拥挤的定义: 在进化过程中, 种群中大量个体逐渐变得非常相似, 甚至被少数高适应度个体及其后代占据, 导致种群多样性下降的现象。

如何降低拥挤:

1. 提高变异概率;
2. 保持种群多样性;
3. 避免过强的选择压力;
4. 采用小生境技术;
5. 采用适应度共享;
6. 引入随机新个体;
7. 限制相似个体同时保留。

线性分类器

几何意义：

线性判别函数 $f(x) = w^T x + w_0$ 的几何意义是：方程 $w^T x + w_0 = 0$ 表示特征空间中的一个分类超平面。权向量 w 是该超平面的法向量，决定超平面的方向；偏置 w_0 决定超平面的位置。该超平面将特征空间划分为两个半空间，若 $f(x) > 0$ ，则样本属于一类；若 $f(x) < 0$ ，则样本属于另一类。样本点到超平面的距离为 $\frac{|w^T x + w_0|}{\|w\|}$ 。

线性分类器的权值更新与梯度下降推导

1. 线性分类器模型

设输入样本为：

$$x = (x_1, x_2, \dots, x_n)$$

权值向量为：

$$w = (w_1, w_2, \dots, w_n)$$

偏置项为：

$$b$$

线性分类器的输出为：

$$\hat{y} = w^T x + b$$

即：

$$\hat{y} = \sum_{j=1}^n w_j x_j + b$$

其中：

- y 表示真实类别；
- $\hat{y}$ 表示模型预测值；
- w_j 表示第 j 个特征对应的权值；
- x_j 表示第 j 个特征值；
- η 表示学习率。

2. 定义误差函数

为了衡量预测值和真实值之间的差距，定义平方误差函数：

$$E = \frac{1}{2}(y - \hat{y})^2$$

其中加上 $\frac{1}{2}$ 是为了后续求导时抵消平方项产生的系数 2，使公式更简洁。

3. 梯度下降法则

梯度下降的基本思想是：沿着误差函数下降最快的方向更新参数。

权值更新公式为：

$$w_j \leftarrow w_j - \eta \frac{\partial E}{\partial w_j}$$

其中：

- η 是学习率；
- $\frac{\partial E}{\partial w_j}$ 表示误差函数对权值 w_j 的偏导数。

4. 求误差函数对权值的偏导

已知：

$$E = \frac{1}{2}(y - \hat{y})^2$$

并且：

$$\hat{y} = \sum_{j=1}^n w_j x_j + b$$

根据链式法则：

$$\frac{\partial E}{\partial w_j} = \frac{\partial E}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial w_j}$$

先求第一部分：

$$\frac{\partial E}{\partial \hat{y}} = \frac{\partial}{\partial \hat{y}} \left[\frac{1}{2}(y - \hat{y})^2 \right]$$

$$\frac{\partial E}{\partial \hat{y}} = -(y - \hat{y})$$

再求第二部分：

$$\frac{\partial \hat{y}}{\partial w_j} = x_j$$

因此：

$$\frac{\partial E}{\partial w_j} = -(y - \hat{y})x_j$$

5. 代入梯度下降公式

梯度下降更新规则为：

$$w_j \leftarrow w_j - \eta \frac{\partial E}{\partial w_j}$$

将：

$$\frac{\partial E}{\partial w_j} = -(y - \hat{y})x_j$$

代入可得：

$$w_j \leftarrow w_j - \eta [-(y - \hat{y})x_j]$$

所以：

$$w_j \leftarrow w_j + \eta (y - \hat{y})x_j$$

因此，线性分类器的权值更新公式为：

$$w_j \leftarrow w_j + \eta (y - \hat{y})x_j$$

6. 偏置项的更新

由于：

$$\hat{y} = w^T x + b$$

所以：

$$\frac{\partial \hat{y}}{\partial b} = 1$$

因此：

$$\frac{\partial E}{\partial b} = -(y - \hat{y})$$

根据梯度下降：

$$b \leftarrow b - \eta \frac{\partial E}{\partial b}$$

代入可得：

$$b \leftarrow b - \eta [-(y - \hat{y})]$$

所以：

$$b \leftarrow b + \eta(y - \hat{y})$$

7. 向量形式

如果将偏置项并入权值向量，令：

$$x_0 = 1, \quad w_0 = b$$

则线性分类器可以写成：

$$\hat{y} = w^T x$$

权值更新公式可以统一写为：

$$w \leftarrow w + \eta(y - \hat{y})x$$

8. 感知机线性分类器的更新规则

如果题目中的线性分类器特指感知机，则通常使用二分类标签：

$$y \in \{-1, +1\}$$

感知机的分类函数为：

$$\hat{y} = \text{sign}(w^T x + b)$$

若样本分类正确：

$$y(w^T x + b) > 0$$

则权值不更新。

若样本被误分类：

$$y(w^T x + b) \leq 0$$

则更新：

$$w \leftarrow w + \eta y x$$

$$b \leftarrow b + \eta y$$

若采用感知机分类规则，当样本被误分类时：

$$w \leftarrow w + \eta y x, \quad b \leftarrow b + \eta y$$

分类正确时权值不变。

Delta 法则

Delta 法则也叫 **LMS 法则 (Least Mean Squares)**，常用于线性神经元或 **Adaline**（自适应线性元件）模型。

它与感知机算法不同，不是直接根据“分错与否”来决定是否更新，而是根据模型输出与真实标签之间的误差大小来进行连续的梯度更新。

1. 误差函数 (Error Function)

Delta 法则通常通过最小化平方误差 (**Squared Error**) 来寻找最优参数：

$$E = \frac{1}{2}(t - o)^2$$

参数说明：

- t (Target)：样本的真实值（期望输出）。
- o (Output)：网络的实际线性输出，计算公式为：

$$o = w^T x + b$$

2. 更新公式 (Update Rules)

为了最小化误差 E ，我们对权重和偏置使用**梯度下降法 (Gradient Descent)**。通过对 E 分别求 w 和 b 的偏导数，可以推导出如下更新公式：

$$w \leftarrow w + \eta(t - o)x$$
$$b \leftarrow b + \eta(t - o)$$

其中 η (Eta) 表示**学习率 (Learning Rate)**，用于控制每次更新的步长大小。

特征选择算法

特征选择三种方式

- 过滤式(Filter)

具体方法：

- 方差选择法：看特征取值的变化
- 相关系数，特征与标签的相关程度
- 卡方检验
- 信息增益

优缺点：

- 速度快
- 适合高维数据
- 不容易过拟合
- 忽略组合效果
- 删除单独看起来不强，组合起来很有用的特征

- 包裹式(Wrapper)

具体方法：

- 前向选择：每次挑最有用的加进去。优点是计算量小，缺点是容易陷入局部最优
- 后向删除：每次挑最没用的删除，优点是考虑了整体作用，缺点是计算量大
- 双向搜索:前两个的结合体，既可以加入又可以删除，优点是比前向选择更灵活，缺点是计算量大
- 穷举:字面意思
- 随机搜索和遗传算法

优缺点：

- 考虑组合关系
- 直接以模型性能作为评价标准
- 计算量大
- 过拟合验证集

- 嵌入式方法

具体方法：

- L1正则化

- 决策树特征选择

- 随机森林

优缺点：

- 训练和特征选择同时进行

- 更贴近模型性能

- 不同模型选择出来的特征不同

- 依赖具体模型